

O que distingue este trabalho

Fábrica de software multi-agente — resumo comparativo

Enzo Consulo · 29 de agosto de 2026 · repositório público: github.com/enzoconsulo/Generic-Multi-Agents

1. Primeiro, o regime — sem isso a comparação engana

O ChatDev reporta **22.949 tokens para produzir um software inteiro**. Aqui, o contexto de **um único despacho** ficou entre 11 e 14 mil tokens depois de otimizado, e um trabalho real consumiu 2,44 milhões só de leitura. Duas ordens de grandeza separam os problemas.

Num regime de sessão única, perda de contexto quase não morde — tudo cabe no diálogo. Num regime de semanas, ela é o problema central, e passam a ser necessários mecanismos que no primeiro nem fariam sentido: estado que sobrevive à sessão, contexto diferenciado por papel, começo de requisição reaproveitável e contabilidade por chamada. Os sistemas não são concorrentes; resolvem problemas de tamanhos diferentes.

2. A origem da proposta

Não veio de um produto observado. Veio de um diagnóstico registrado na documentação antes de existir código: **as falhas não são de escrita, são de processo**. Quatro modos aparecem sempre — perda de contexto, decisão sem rastro, autoaprovação e tentativa sem limite — e nenhum se resolve com um modelo melhor. Daí as três regras: quem implementa nunca é quem aprova; estado fora da conversa; falha limitada. E a tese: o gargalo não está na geração de texto, e sim na governança.

3. As quatro diferenças reais

Dimensão	ChatDev / MetaGPT	softwarefabrik.io	Este trabalho
Onde vive o estado	Memória de diálogo, comprimida entre fases	Espaço de trabalho e o operador humano	Arquivo de tarefa e banco; a conversa nunca é fonte
O que o revisor recebe	O mesmo histórico da fase: o papel muda, o contexto não	As diferenças finais, para decisão humana	Só as mudanças, e nenhum fonte inteiro
Para que o custo é medido	Comparar frameworks, no artigo	Estimar antes de executar	Reprojetar: a medição decide onde mexer
O que acontece ao falhar	Dez rodadas, ou duas modificações sem mudança	O operador decide	Escada: sobe modelo, troca especialista, replaneja, bloqueia

Duas correções honestas, que versões anteriores desta comparação erravam: o revisor do ChatDev também não edita código, e o limite de dez rodadas é um limite real. O que distingue aqui não é ter limite, e sim a escada — em especial o terceiro degrau, que trata o fracasso repetido como possível erro de dimensionamento da tarefa e a redivide automaticamente. E a proibição de corrigir não é convenção de protocolo: é ausência da ferramenta no catálogo do papel, com teste que garante.

4. A economia do contexto — a alavanca mais específica

A interface do modelo não tem memória: todo o histórico é reenviado a cada chamada. Logo, **um arquivo que o revisor nunca vai abrir não é um desperdício de uma vez, é um desperdício multiplicado pelo número de voltas do despacho**.

Alavanca	O que é
Começo estável e reaproveitado	Ferramentas, doutrina e índice do projeto idênticos entre despachos — o trecho repetido cai a cerca de um décimo do preço

Contexto por papel	Quem constrói leva os arquivos da tarefa; quem revisa leva só as mudanças
Checagem por comando antes do modelo	Critérios escritos como comando executável rodam de graça, antes do despacho
Modelo conforme o papel	Verificar é mecânico e usa o modelo barato; o retrabalho sobe de modelo
Trabalho em lote	Reindexação e documentação vão pela via assíncrona, que cobra metade

Medido: o revisor passou a sair sem nenhum arquivo embutido, contra dois ou três do construtor da mesma tarefa, com o contexto do papel caindo de cerca de 35 mil para 15 mil tokens. E a medição revelou que 93,14% dos tokens de entrada já eram leitura reaproveitada, enquanto a escrita — 6,66% dos tokens — carregava cerca de metade da conta. Foi esse número que redirecionou o redesenho.

5. O que é herdado, e o que é convergência

A citar, não a reivindicar: o termo “fábrica de software” (CUSUMANO, 1991); papéis especializados e limite de iteração (ChatDev, MetaGPT, 2023); portão de qualidade, modelo por papel e estimativa de custo (softwarefabrik.io); agente como processo supervisionado em OTP (prática corrente em Elixir).

A semelhança é convergência, não cópia, e o argumento mais forte é este: **as soluções divergem onde o problema é o mesmo**. A autoaprovação é atacada pelos três — o comercial põe um humano no portão, ao custo da autonomia; os acadêmicos usam convenção de protocolo; este remove a ferramenta do catálogo do papel.

6. A evidência

Commit	Data	O que registra
8215dbf	01/08	Índice denso do projeto no lugar da varredura de arquivos
1a41ca8	02/08	Montador de contexto por papel e teto de custo com parada limpa
91559b8	02/08	O laço de orquestração vira código testado
8017c41	02/08	O pipeline decide sozinho, sem portão de julgamento humano
696762e	31/07	Um ganho de 12% remedido, identificado como ruído e retirado
e8974c5	21/08	Hipótese de gargalo avaliada e descartada: 0 s de fila em 43 rodadas

Os dois últimos são os mais relevantes para a defesa do método: em ambos a medição contrariou a hipótese e o rumo mudou. São 205 commits em seis semanas, com os conceitos aparecendo depois dos incidentes que os motivaram; e, em operação real, 86 tarefas concluídas de 89, em três projetos de domínios distintos, com 139 execuções gravadas.